

Çoklu ViT Tabanlı Özellik Füzyonu ile HiperKvasir 23-Sınıf Gastrointestinal Görüntü Sınıflandırması

Yasin Ekici

Öğrenci No: 21360859029

<https://github.com/YasinEkici/hyperkvasir-multi-backbone-fusion>

25 Haziran 2026

Özet

Bu çalışmada, HiperKvasir veri kümesindeki 23 sınıflı ve sınıf dağılımı oldukça dengesiz gastrointestinal endoskopi görüntü sınıflandırması problemi ele alınmaktadır. Önceden eğitilmiş üç görüntü dönüştürücü (Vision Transformer) omurga ağı — ViT-B/16, Swin-T ve BEiT-B/16 — özellik çıkarıcı olarak kullanılmış; her daldan elde edilen 768 boyutlu havuzlanmış öznitelikler 512 boyuta izdüşürülerek birleştirme (concatenation), ağırlıklı ve gelişmiş bir kapılı (GMU) füzyon yöntemiyle birleştirilmiş ve sabit bir çok katmanlı algılayıcı (MLP) ile sınıflandırılmıştır. Hem dondurulmuş öznitelik çıkarımı hem de son dönüştürücü bloklarının ince ayarı (fine-tune) değerlendirilmiştir. Değerlendirme, sızıntıya karşı denetlenmiş resmi 5-katlı protokol altında yürütülmüş; ana ölçüt olarak makro-F1, destekleyici ölçüt olarak doğruluk kullanılmış ve sonuçlar önyükleme (bootstrap) %95 güven aralıklarıyla raporlanmıştır. Çapraz doğrulamada en iyi yapılandırma, üç omurganın ağırlıklı füzyonunun ince ayarlı sürümü olmuştur (havuzlanmış makro-F1 0,6119, %95 GA [0,5930, 0,6295]; doğruluk $\approx 0,88$). Bu yapılandırma, eşli McNemar testinde en iyi tekli omurgadan ve en iyi ikili füzyondan istatistiksel olarak anlamlı biçimde daha doğru bulunmuştur. Gelişmiş GMU füzyonu birleştirmeye kıyasla kazanım sağlamamış; test zamanı veri artırma (TTA) ve sızıntısız seed topluluğu güven aralığı düzeyinde ayırt edilebilir bir iyileşme getirmemiş; son işlem olarak uygulanan logit düzeltmesi ise makro-F1'i düşürmüştür. Havuzlanmış makro-F1 ($\approx 0,61$) ile doğruluk ($\approx 0,88$) arasındaki büyük fark, dengesizliğin doğrudan kanıtıdır: çok düşük destekli nadir sınıflar makro-F1'i aşağı çeker. Literatür sonuçları, protokol farkları nedeniyle yalnızca bağlamsal olarak ele alınmış; güncel-en-iyi (state-of-the-art) bir başarı iddiasında bulunulmamıştır.

1 Giriş

Gastrointestinal (GI) endoskopi görüntülerinin otomatik sınıflandırılması, tarama ve tanı süreçlerinde uzman iş yükünü azaltma potansiyeli taşıyan bir bilgisayarlı görü problemidir. Bu çalışmada, halka açık **HiperKvasir** veri kümesinin 23 sınıflı etiketli alt kümesi üzerinde, anatomik dönüm noktaları, patolojik bulgular ve tedavi/aletsel durumları kapsayan çok sınıflı bir sınıflandırma görevi ele alınmaktadır [6]. Veri kümesinin başlıca zorluğu, sınıf dağılımının *aşırı dengesiz* olmasıdır: bazı sınıflar binlerce görüntüye sahipken, bazı nadir sınıflar yalnızca onlu sayılarda örnek içerir.

Önerilen yaklaşım, tek bir omurga yerine *birden çok görüntü dönüştürücü* (Vision Transformer, ViT) omurgasını özellik çıkarıcı olarak kullanıp bunların özniteliklerini birleştiren bir özellik füzyonu mimarisidir. Üç farklı tümleyici omurga seçilmiştir: saf yerel-olmayan dikkat temelli **ViT-B/16**, hiyerarşik kaydırmalı-pencere temelli **Swin-T** ve maskeli görüntü modellemesiyle öz-denetimli ön-eğitilmiş **BEiT-B/16**. Bu üçlü; küresel öz-dikkat (ViT), hiyerarşik yerel-çok ölçekli temsil (Swin) ve öz-denetimli ön-eğitim (BEiT) gibi farklı tüm dengelimsel önyargıları bir araya getirir; böylece tek bir mimari ailesine bağlı kalmadan tamamlayıcı temsiller öğrenmeyi amaçlar.

Çalışmanın karşılaştırma eksenleri üç düzeydedir: (i) *omurga düzeyinde* (tekli/ikili/üçlü kombinasyonlar), (ii) *füzyon düzeyinde* (birleştirme, ağırlıklı ve kapılı GMU füzyonu) ve (iii) *transfer öğrenme düzeyinde* (dondurulmuş öznitelik çıkarımı ile son blokların ince ayarı). Sınıflandırıcı tüm yapılandırmalarda sabit tutulmuştur (tek bir MLP); dolayısıyla sınıflandırıcı-düzeyinde bir karşılaştırma *yapılmamıştır*, böylece gözlemlenen tüm farklar omurga, füzyon ve transfer seçimlerine atfedilebilir.

Ana katkı ve bulgular şu şekilde özetlenebilir:

- Üç ViT omurgasının ağırlıklı füzyonu, resmi 5-katlı protokolde en iyi makro-F1 değerini vermiştir; bu yapılandırma eşli McNemar testinde en iyi tekli omurgadan ve en iyi ikili füzyondan anlamlı biçimde daha doğrudur.
- Gelişmiş kapılı füzyon (GMU), ağırlıklı füzyona kıyasla bir kazanım sağlamamıştır.
- Modelin başarısı, dengesizlik nedeniyle bir tavana ulaşmıştır: yüksek doğruluk (%88) ile daha düşük makro-F1 ($\approx 0,61$) arasındaki fark, nadir sınıfların başarımı sınırladığını açıkça gösterir. Bu olgu, dikkat haritaları, Grad-CAM++ ve UMAP görselleştirmeleriyle de desteklenmiştir.

2 İlgili Çalışmalar

Görüntü dönüştürücüleri. ViT [9], görüntüyü yamalara bölüp bir dönüştürücü kodlayıcıya besleyerek evrimsel önyargı olmadan küresel bağımlılıkları modeller. Swin [14] hiyerarşik ve kaydırmalı pencere dikkatiyle hesaplama maliyetini düşürürken çok ölçekli temsiller üretir. BEiT [5] ise maskeli görüntü modellemesiyle öz-denetimli ön-eğitim kullanır. Bu üç omurga farklı tümevarımsal önyargılara ve ön-eğitim rejimlerine sahip olduğundan, füzyon için tamamlayıcı adaylardır.

Çok kaynaklı özellik füzyonu. Birden çok omurganın özniteliklerini birleştirmenin en yaygın yolları doğrudan *birleştirme* (concatenation) ve *ağırlıklı* toplamadır. Daha gelişmiş bir seçenek, her modaliteye/dala öğrenilen kapılarla ağırlık veren *Kapılı Çok Modlu Birim* (GMU)'dir [4]. Öznitelik füzyonu tıbbi görüntülerde de etkin kullanılmıştır: GI endoskopide CNN özniteliklerinin birleştirilip ayrı bir sınıflandırıcıyla değerlendirilmesi [2] ve çok ölçekli temsiller için uyarlanır çok-dikkatli hiyerarşik füzyon [11] önerilmiştir. Bu çalışmada birleştirme, ağırlıklı ve GMU yöntemlerinin üçü de uygulanmış ve karşılaştırılmıştır.

HiperKvasir ve GI endoskopi sınıflandırması. HiperKvasir, GI endoskopi için geniş, çok sınıflı ve halka açık bir referans veri kümesidir [6]. Dönüştürücü temelli yaklaşımlar arasında hiyerarşik kaydırmalı-pencere ViT [22] ve önceden eğitilmiş ViT toplulukları [3] yer alır; verimli karışım yöntemleri [18] de yüksek toplu doğruluklar bildirir. CNN ve dönüştürücü temsillerini birleştiren melez modeller, endoskopi ve video-kapsül görüntülerinde umut verici sonuçlar vermiş [20]; kaynak-kısıtlı ortamlar için MobileViT gibi hafif dönüştürücüler ise F1 ile model boyutu arasındaki dengeyi araştırmıştır [21]. HiperKvasir'in geniş etiketsiz alt kümesinden yararlanan müfredat temelli öz-denetimli ön-eğitim de GI sınıflandırmasında raporlanmıştır [10]; bu yaklaşım, BEiT'in öz-denetimli ön-eğitim çizgisiyle örtüşür. Bu çalışmalar genellikle farklı bölme protokolleri, farklı veri kümeleri veya sınıf alt kümeleri kullandığından doğrudan sayısal kıyas yanıltıcıdır; ilgili sonuçlar Bölüm 5'te *bağlamsal* olarak ele alınır.


Yorumlanabilirlik. Dönüştürücülerde karar gerekçelerini görmek için *dikkat yayılımı* (attention rollout) [1], kalıntı bağlantıları hesaba katarak katmanlar arası dikkat akışını yaklaşıklar. Grad-CAM++ [7] (ve temeli Grad-CAM [19]), gradyan tabanlı sınıfa özgü ısı haritaları üretir. Öznitelik uzayının yapısını incelemek için boyut indirgeme yöntemi UMAP [16] kullanılmıştır.

Model karşılaştırmalarının istatistiksel anlamlılığı için eşli McNemar testi [8], dengesizlik için ise son-işlem logit düzeltmesi [17] ele alınmıştır.

3 Yöntem

3.1 Genel mimari

Önerilen model dört aşamadan oluşur: (1) paralel ViT omurgalarıyla öznitelik çıkarımı, (2) dal başına izdüşüm, (3) füzyon ve (4) MLP sınıflandırıcı. Şekil 1 bu akışı şematik olarak gösterir.



Şekil 1: Üçlü ViT füzyon mimarisi. Aynı 224×224 görüntü üç omurgaya verilir; her omurga `timm` üzerinden `num_classes=0` ile yüklenip 768 boyutlu havuzlanmış öznitelik üretir. Her dal 512 boyuta izdüşürülür, ağırlıklı füzyonla birleştirilir ve tek bir MLP (gizli 256, dropout 0,3) ile 23 sınıfa sınıflandırılır. Omurgalar dondurulmuş öznitelik çıkarımı veya son bloklarının ince ayarı ile kullanılır.

3.2 Omurgalar ve öznitelik çıkarımı

Üç omurga, farklı tümevarımsal önyargılara ve ön-eğitim rejimlerine sahip olacak biçimde seçilmiştir. ViT [9] görüntüyü yamalara bölüp standart bir dönüştürücü kodlayıcıya verir; evrimsel yerellik ve öteleme-değişmezlik önyargısı taşımadığından küresel öz-dikkatle uzun-erimli ilişkileri modeller, fakat güçlü temsil için büyük ölçekli ön-eğitime ihtiyaç duyar. Swin [14] yamaları derin katmanlarda birleştirip kaydırmalı-pencere öz-dikkati kullanarak *hiyerarşik* ve yerel-çok ölçekli temsiller üretir; bu, evrışıme benzer bir yerellik önyargısını geri kazandırır ve doku ile sınır gibi yerel ipuçlarına duyarlıdır. BEiT [5] ise maskeli görüntü modellemesiyle (yamaların bir bölümünü maskeleyip görsel belirteçleri geri kazanma) *öz-denetimli* ön-eğitilir ve denetimli ViT'ten farklı bir temsil öğrenir. Bu üç ayrı önyargı, füzyon için tamamlayıcı sinyaller sağlar.

Her omurga `timm` kütüphanesinden ImageNet üzerinde ön-eğitilmiş ağırlıklarla yüklenir. Sınıflandırma başlığı `num_classes=0` ile kaldırılır ve mimariye uygun yerel havuzlanmış öznitelik vektörü ($\mathbb{R}^{768}$) elde edilir. Bu yaklaşım hem CLS-belirteçli (ViT, BEiT) hem de CLS-belirteçsiz (Swin, küresel ortalama havuzlama) mimarilerde doğru çalışır.

3.3 İzdüşüm, füzyon ve sınıflandırıcı

Bu aşamada her omurganın 768 boyutlu özneliği ortak bir uzaya indirgenir, üç dal tek bir vektörde birleştirilir ve sonuç sabit bir sınıflandırıcıya verilir.

3.3.1 Dal izdüşümü

Her dalın öz niteliği, ardışık $Doğrusal \rightarrow LayerNorm \rightarrow GELU$ katmanıyla 512 boyutlu ortak bir uzaya izdüşürülür.

3.3.2 Füzyon yöntemleri

Üç füzyon yöntemi uygulanmıştır:

- **Birleştirme:** dal öz nitelikleri uç uca eklenir ($N \times 512$).
- **Ağırlıklı:** öğrenilen skaler ağırlıklarla normalize toplam (512).
- **GMU:** her dala öğrenilen *öğre bazında* (per-feature) kapılarla ağırlık veren kapılı füzyon [4]. İki dal için bu, özgün makalenin $h = z \odot h_v + (1 - z) \odot h_t$ biçimine *tam olarak* indirgenir.

İzdüşürülmüş dal öz nitelikleri $h_i \in \mathbb{R}^{512}$ ($i = 1, \dots, N$) için füzyon işlemleri şöyle tanımlanır:

$$\text{Birleştirme: } f = [h_1; h_2; \dots; h_N] \in \mathbb{R}^{N \cdot 512}, \quad (1)$$

$$\text{Ağırlıklı: } \alpha = \text{softmax}(w), \quad f = \sum_{i=1}^N \alpha_i h_i, \quad (2)$$

$$\text{GMU: } z = \text{softmax}_{\text{dal}}(W_z [h_1; \dots; h_N]), \quad f = \sum_{i=1}^N z_i \odot h_i. \quad (3)$$

Ağırlıklı füzyonda $w \in \mathbb{R}^N$ öğrenilen skaler ağırlıklardır (α_i skalerdir); GMU’da $z_i \in \mathbb{R}^{512}$ öğre-bazında kapılardır ve dal ekseninde normalize edilir, dolayısıyla her öz nitelik boyutu için ayrı ağırlıklandırma yapılır. İki dal durumunda GMU, $f = z \odot h_1 + (1 - z) \odot h_2$ biçimine indirgenir.

3.3.3 Sınıflandırıcı

Füzyon çıktısı tek bir MLP’ye (256 gizli birim, dropout 0,3) verilir. Tüm yapılandırmalarda sınıflandırıcı sabittir.

3.4 Transfer öğrenme rejimleri

İki rejim karşılaştırılmıştır: (i) *dondurulmuş* öz nitelik çıkarımı (omurga ağırlıkları sabit, yalnızca izdüşüm + füzyon + MLP eğitilir) ve (ii) *ince ayar*: ViT/BEiT’te son üç dönüştürücü bloğu, Swin’de son aşama açılır; ayrıca son normalizasyon katmanı eğitilir. Yalnız son blokların açılması bilinçli bir tercihtir: küçük ve dengesiz bir veri kümesinde tüm ağı açmak, ImageNet ön-eğitiminde edinilen genel öz nitelikleri bozabilecek felakete-varan unutmaya (catastrophic forgetting) yol açar; buna karşılık son bloklar göreve/alana özgü olduğundan uç (endoskopi) alanına uyarlanmaya en uygun katmanlardır. Aynı gerekçeyle ince ayar, katman bazında azalan öğrenme oranı (LLRD) ile uygulanır [12]: çıkışa yakın katmanlar daha yüksek, gövdeye yakın (daha genel) katmanlar daha düşük öğrenme oranıyla güncellenir, böylece genel temsiller korunurken üst katmanlar alana uyarlanır.

3.5 Yorumlanabilirlik ve istatistiksel analiz

Nihai model için (a) CLS-belirteçli ViT-B ve BEiT-B dallarında *dikkat yayılımı* [1]: ham dikkat, derin katmanlarda belirteç kimliğini yitirdiğinden tek başına güvenilir bir açıklama vermez; kalıntı bağlantılarını hesaba katmak için her katmanda $A = 0,5 W_{\text{att}} + 0,5 I$ alınır (birim matris kalıntı yolunu temsil eder), katmanlar boyunca özyinelemeli çarpılır ve CLS satırı 14×14 ızgaraya eşlenir; (b) üç dalda *Grad-CAM++* [7]; (c) 512 boyutlu füzyon öz nitelikleri üzerinde *UMAP* [16] görselleştirmesi; (d) eşli *McNemar* testi [8] ve (e) son-işlem *logit düzeltmesi* [17] uygulanmıştır.

Tüm bu çözümlemeler, eğitilmiş kontrol noktalarından *yalnızca çıkarım* yoluyla üretilmiş ve nihai modeli değiştirmemiştir.

4 Deneyler

4.1 Veri kümesi ve bölme protokolü

HiperKvasir'in 23 sınıflı etiketli alt kümesi kullanılmıştır ($n = 10.662$ görüntü). Değerlendirme, veri kümesiyle birlikte sağlanan *resmi 5-katlı* bölme üzerinden yürütülmüştür. Her katın kendi tutulan (held-out) test bölümü vardır ve beş kat ayrıktır; bu nedenle birleştirilmiş (havuzlanmış) tahminler tüm veri kümesini tam olarak bir kez kapsar. Sızıntıyı önlemek için *kat modelleri asla makro-F1 hesabından önce ortalalmaz*; tüm güven aralıkları, ayrı kat-dışı (OOF) test tahminlerinden tekrar örnekleyerek makro-F1 dağılımını kestiren önyükleme (bootstrap) yöntemiyle hesaplanır.

4.2 Ön işleme

Görüntüler ImageNet ortalaması/standart sapmasıyla normalize edilir; en kısa kenar 256'ya ölçeklenip eğitimde rastgele, değerlendirmede merkez 224×224 kırpma uygulanır. Yeniden boyutlandırma, `timm` ViT ağırlıklarıyla tutarlı olacak şekilde *biküçük* aradeğerleme ile yapılır.

4.3 Eğitim reçetesi

İnce ayar reçetesi şu bileşenleri içerir: AdamW eniyileyici [15] (omurga öğrenme oranı 5×10^{-5} , başlık 10^{-3} , ağırlık sönümü 0,05), katman bazında azalan öğrenme oranı (LLRD, 0,7), 5 epoch ısınma ile kosinüs zamanlayıcı, stokastik derinlik (drop-path 0,05), etiket yumuşatma 0,1, hafif MixUp (0,2; küçük lezyonları silmemek için CutMix kapalı), üstel hareketli ortalama (EMA, 0,9998) ve dengesizlik için ağırlıklı örnekleyici (sınıf frekansının tersiyle örnekleme yaparak nadir sınıfları daha sık görünür kılan WeightedRandomSampler). Yığın boyutu 32, en fazla 60 epoch, doğrulama makro-F1 üzerinde erken durdurma. Tek bir model ailesinin önyargısını azaltmak için ViT-B/BEiT-B'de son üç blok, Swin'de son aşama açılmıştır. Bu düzenleyici bileşenlerden stokastik derinlik (drop-path), eğitimde bazı katmanları rastgele atlayarak aşırı uyumu sınırlar; MixUp, örnek çiftlerini ve etiketlerini doğrusal harmanlayarak karar sınırlarını yumuşatır; etiket yumuşatma, hedef dağılımı tek-sıcak yerine biraz yumuşatarak aşırı güveni azaltır; EMA ise model ağırlıklarının üstel hareketli ortalamasını tutarak değerlendirmede daha kararlı bir model sağlar. Tablo 1 ince ayar hiperparametrelerini özetler.

Tablo 1: İnce ayar hiperparametreleri.

Hiperparametre	Değer
Eniyileyici	AdamW
Omurga öğrenme oranı	5×10^{-5}
Başlık öğrenme oranı	10^{-3}
Katman bazında azalım (LLRD)	0,7
Ağırlık sönümü	0,05
Zamanlayıcı	kosinüs, 5 epoch ısınma
Stokastik derinlik (drop-path)	0,05
Etiket yumuşatma	0,1
MixUp / CutMix	0,2 / kapalı
EMA sönümü	0,9998
Yığın boyutu	32
Açılan katmanlar	ViT-B/BEiT-B son 3 blok; Swin son aşama
Epoch (maks.) / erken durdurma	60 / sabır 8
Görüntü / normalizasyon	224×224, ImageNet, bikübik
Karışık hassasiyet	bfloat16 + TF32

4.4 Hesaplama ve verimlilik

İnce ayar koşulları Google Colab Pro A100 üzerinde yürütülmüştür. Veri yükleyici paralellliği, TF32 ve bfloat16 otomatik hassasiyet ile cuDNN otomatik ayarı etkinleştirildiğinde, A100 verimi temel yapılandırmaya göre yaklaşık $5,3\times$ (tekli) – $5,9\times$ (üçlü) artmıştır; üreme (reproducibility) yaklaşıktır (seed’ler sabit tutulmuştur). Dondurulmuş eleme koşulları ise A100 dışında çalıştırılarak hesaplama bütçesi korunmuştur.

4.5 Ölçütler

Ana ölçüt *makro-F1*’dir; doğruluk, makro kesinlik/duyarlılık, sınıf bazında metrikler ve karışıklık matrisi destekleyici olarak raporlanır. Eleme aşaması yalnızca 0. katta, seçilen en iyi dört yapılandırma ise tam 5-katlı çapraz doğrulamada değerlendirilmiştir; bu huni, hesaplama bütçesini korur. Bildirilen tüm sayılar, her kat için kaydedilen değerlendirme çıktılarından üretilmiştir.

5 Sonuçlar

5.1 Dondurulmuş eleme ve transfer kazanımı

Tüm tekli/ikili/üçlü yapılandırmalar önce 0. katta dondurulmuş rejimde sıralanmıştır. Dondurulmuş rejimde en güçlü *tekli* omurga Swin-T (makro-F1 0,576), en güçlü *üçlü* ise ağırlıklı füzyon (0,565) olmuştur; tek başına BEiT-B en zayıf omurgadır (0,522). Son blokların ince ayarı, eleme adayı her yapılandırmada makro-F1’i artırmıştır (Tablo 3); en büyük kazanım ikili ve üçlü füzyon yapılandırmalarında görülmüştür. Bu, küçük veri rejiminde bile son dönüştürücü bloklarının uç (endoskopi) alanına uyarlanması değerli olduğunu gösterir. Tablo 2 tüm yapılandırmaların dondurulmuş sıralamasını verir.

Tablo 2: 0. kat dondurulmuş eleme sıralaması (makro-F1’e göre). V=ViT-B, S=Swin-T, B=BEiT-B.

#	Omurga	Füzyon	Doğruluk	Makro-F1
1	S	yok	0,8704	0,5760
2	V+S+B	weighted	0,8511	0,5649
3	S+B	weighted	0,8779	0,5648
4	V+S	concat	0,8803	0,5618
5	V+B	concat	0,8539	0,5613
6	S+B	concat	0,8657	0,5598
7	V+S	weighted	0,8695	0,5580
8	V	yok	0,8417	0,5576
9	V+B	weighted	0,8582	0,5530
10	V+S+B	concat	0,8520	0,5517
11	B	yok	0,8318	0,5215

Tablo 3: 0. kat dondurulmuş $\rightarrow$ ince ayar makro-F1 farkları (ince ayar – dondurulmuş).

Yapılandırma	Füzyon	Δ Doğruluk	Δ Makro-F1
Swin-T (tek)	yok	+0,007	+0,016
V+S birleştirme	concat	-0,011	+0,011
V+B birleştirme	concat	+0,012	+0,017
S+B ağırlıklı	weighted	-0,007	+0,026
V+S+B ağırlıklı	weighted	+0,028	+0,020

İnce ayarın yakınsama hızı ve görelî maliyeti Tablo 4’te verilmiştir. Her iki rejim de en iyi doğrulama makro-F1’ine birkaç epoch içinde ulaşır; dondurulmuş rejim daha hızlıdır ve A100 gerektirmez. İnce ayarın ek maliyeti, verimlilik ayarıyla (TF32, bfloat16, veri yükleyici paralelliği) yaklaşık 5,3–5,9 $\times$ azaltılarak bütçe içinde tutulmuştur.

Tablo 4: Transfer maliyeti: en iyi doğrulama epoch’u (yakınsama hızı) ve ayarlı A100 verim kazancı. Eğitim süresi loglanmadığından maliyet, yakınsama epoch’u ve görelî verimle ifade edilir.


Yapılandırma	Dondurulmuş (en iyi epoch)	İnce ayar (en iyi epoch)	Ayarlı verim kazancı
Swin-T (tek)	4	6	$\sim 5,3\times$
V+S+B	4	6	$\sim 5,9\times$

5.2 5-katlı çapraz doğrulama

Seçilen en iyi dört yapılandırma tam 5-katlı çapraz doğrulamada değerlendirilmiştir (Tablo 5, Şekil 2). **Üç omurganın ağırlıklı füzyonu** (V+S+B), $0,6094 \pm 0,0254$ ortalama ve 0,6119 havuzlanmış makro-F1 (%95 GA [0,5930, 0,6295]) ile en iyi yapılandırmadır ve nihai model olarak seçilmiştir. En iyi tekli omurga (Swin-T, havuzlanmış 0,5985) ve en iyi ikili füzyon (S+B ağırlıklı, 0,5893) bunu izler. Füzyonun katkısı Bölüm 6’da istatistiksel olarak da incelenmiştir.

Tablo 5: 5-katlı CV sıralaması (makro-F1 ortalamasına göre). Önyükleme %95 GA, ayrık OOF test tahminleri üzerinden.

Yapılandırma	Füzyon	Doğruluk (ort±std)	Makro-F1 (ort±std)	Makro-F1 havuz [%95 GA]
V+S+B	weighted	0,8780 ± 0,0140	0,6094 ± 0,0254	0,6119 [0,5930, 0,6295]
Swin-T (tek)	yok	0,8679 ± 0,0097	0,5969 ± 0,0261	0,5985 [0,5806, 0,6152]
S+B	weighted	0,8652 ± 0,0058	0,5879 ± 0,0111	0,5893 [0,5736, 0,6054]
V+B	concat	0,8454 ± 0,0084	0,5727 ± 0,0149	0,5753 [0,5638, 0,5863]



Şekil 2: Seçili yapılandırmaların 5-katlı makro-F1 değerleri (ortalama ± standart sapma). Üçlü ağırlıklı füzyon en yüksek ortalamaya sahiptir.

5.3 Nihai modelin ayrıntılı çözümlemesi


Nihai modeli (fold 0) daha yakından inceliyoruz: önce eğitim dinamiği, ardından havuzlanmış karışıklık matrisi ile sınıf bazında başarımlar ele alınır.

5.3.1 Eğitim dinamiği


Şekil 3a nihai modelin (0. kat) eğitim eğrilerini gösterir; eğitim kaybı düzenli azalırken doğrulama makro-F1'i erken bir epoch'ta tepe yapar ve erken durdurma devreye girer.

5.3.2 Karışıklık matrisi ve sınıf bazında başarımlar

Şekil 4 havuzlanmış OOF karışıklık matrisidir. Yaygın sınıflar çok yüksek köşegen değerlerine sahiptir (ör. *normal-pylorus* 0,99, *retroflex-stomach* 0,99, *impacted-stool* 0,99), buna karşılık hataların büyük kısmı *anlamsal/anatomik olarak komşu* sınıflar arasında yoğunlaşır: ülseratif kolit dereceleri birbirine karışır, *hemorrhoids* büyük ölçüde *retroflex-rectum* olarak tahmin edilir ve *oesophagitis-a* *normal-z-line* ile karışır.




(a) Eğitim eğrileri (0. kat).



(b) Sınıf bazında F1 (renk = destek).

Şekil 3: Nihai modelin eğitim dinamikleri ve sınıf bazında başarımları. Düşük destekli sınıflar düşük F1 ile güçlü biçimde ilişkilidir.



Şekil 4: Nihai modelin havuzlanmış ($n = 10.662$) OOF karışıklık matrisi (satur-normalize). Hatalar büyük ölçüde anatomik/ordinal komşu sınıflar arasındadır.

Sınıf bazında metrikler (Tablo 6) bu tabloyu nicelleştirir: yüksek destekli sınıflarda $F1 \approx 0.97-0.99$ iken, en düşük destekli sınıflarda (hemorrhoids: 6, ulcerative-colitis-grade-1-2: 11) F1 sıfıra kadar düşer.

Havuzlanmış OOF üzerinde, ana ölçüt makro-F1'in (0,612) yanında destekleyici toplu ölçütler de hesaplanmıştır: doğruluk 0,878 (tek-etiketli çok-sınıfta mikro-F1'e eşittir), ağırlıklı F1 0,879 ve Matthews korelasyon katsayısı (MCC) 0,868. Makro-F1 ile bu toplu ölçütler arasındaki belirgin açık, dengesizliğin etkisini bir kez daha ortaya koyar; MCC (0,868), veri kümesi makalesinin en iyi CNN temelini (0,899) biraz altında olmakla birlikte aynı bütünsel uyum bandındadır.

Tablo 6: Nihai model: en düşük ve en yüksek F1'li altı sınıf (havuzlanmış OOF).

Sınıf	Kesinlik	Duyarlılık	F1 (Destek)
hemorrhoids	0,00	0,00	0,00 (6)
ulcerative-colitis-grade-1-2	0,00	0,00	0,00 (11)
ulcerative-colitis-grade-2-3	0,05	0,07	0,06 (28)
bbps-0-1	0,98	0,97	0,98 (646)
normal-pylorus	0,98	0,99	0,98 (999)
retroflex-stomach	0,99	0,99	0,99 (764)


5.4 Toplamsal teknikler ve istatistiksel anlamlılık

Nihai model üzerinde denenen toplamsal, sızıntısız teknikler Tablo 7'da özetlenmiştir. Test zamanı veri artırma (TTA) ve sızıntısız seed topluluğu makro-F1'i güven aralığı düzeyinde ayırt edilebilir biçimde artırmamıştır. Son-işlem logit düzeltmesi [17] ise makro-F1'i *düşürmüştür* (Şekil 5): düzeltme gücü τ arttıkça başarımlar tekdüze azalır. Bunun nedeni, modelin zaten dengeli örnekleyici ile eğitilmiş olması ve örtük önselin yaklaşık tekdüze olmasıdır; eğitim önselini çıkarmak *ikinci kez* düzeltme yaparak nadir sınıflara aşırı kayma getirir.

Buna karşılık, eşli **McNemar** testi [8] ($n = 10.662$), üçlü füzyonun en iyi tekli omurgadan ($\chi^2_{cc} = 15,25$, $p = 9,2 \times 10^{-5}$) ve en iyi ikili füzyondan ($\chi^2_{cc} = 25,25$, $p = 4,7 \times 10^{-7}$) *anlamlı biçimde daha doğru* olduğunu göstermiştir. Bu, doğruluk düzeyinde bir testtir; makro-F1 güven aralıklarının kısmen örtüşmesiyle çelişmez, onu tamamlar: füzyon genel olarak anlamlı sayıda doğru tahmin ekler, ancak makro-F1 kazancı nadir sınıflarca sınırlanır.

Tablo 7: Nihai model üzerinde toplamsal teknikler (havuzlanmış OOF makro-F1). Hiçbiri nihai modeli değiştirmez; tümü sızıntısızdır.

Teknik	Havuz makro-F1	Not
Temel (nihai model)	0,6119	headline
Seed topluluğu	0,6157	GA örtüşür (anlamsız)
TTA	—	GA düzeyinde kazanım yok
Logit düzeltmesi ($\tau=1$)	0,4911	düşürür (aşırı düzeltme)
GMU füzyonu (üçlü, 0. kat)	0,5525	ağırlıklının altında



Şekil 5: Son-işlem logit düzeltmesi duyarlılık eğrisi: makro-F1, düzeltme gücü τ ile tekdüze azalır.

5.5 Literatürle bağlamsal karşılaştırma

Sonuçları literatürle konumlandırırken iki noktayı ayrı ele alıyoruz: çalışmalar arasındaki protokol/ölçüt farkları ve bu farkların metrik yorumuna etkisi.

5.5.1 Protokol ve ölçüt farkları

Literatürdeki HiperKvasir çalışmaları farklı bölme protokolleri ve farklı ölçüt tanımları kullandığından, sayılar doğrudan değil *bağlamsal* ele alınmalıdır. Çalışmaların çoğu doğruluk veya genel/ağırlıklı F1 raporlar; sıvıya karşı denetlenmiş bir makro-F1 seyrek verilir. Veri kümesini tanıtan çalışma [6] bir istisnadır: iki-bölme ortalamasıyla *makro-ortalama* F1 raporladığından ölçüt türü bizimkiyle aynıdır, fakat bölme protokolü farklıdır. GastroViT [3] bizimle aynı 23 sınıflı alt kümeyi kullanır ancak topluluk ve farklı bölme ile çalışır; EffiMix [18] ve HSW-ViT [22] de farklı bölmelerde sonuç verir.

Tablo 8: HiperKvasir bağlamsal konumlandırma (protokoller farklı; doğrudan kıyas değil). “–”: karşılaştırılabilir makro-F1 bildirilmemiş. [†]Borgli’nin doğruluğu mikro-F1 olarak verilmiştir (tek-etiketli çok-sınıfta mikro-F1, doğruluğa eşittir).

Çalışma	Yöntem	Protokol	Doğ.	Makro-F1	Diğer
Bu çalışma	ViT füzyonu (V+S+B)	resmi 5-katlı + GA	$\approx 0,88$	0,612	MCC 0,868
Borgli 2020 [6]	CNN (DenseNet-161)	2-bölme ort.	0,907 [†]	0,619	MCC 0,899
GastroViT 2025 [3]	ViT topluluğu	kendi bölmesi	0,920	–	–
HSW-ViT 2023 [22]	HSW-ViT	kendi bölmesi	0,868	–	–
EffiMix 2022 [18]	karışım	kendi bölmesi	0,980	–	ağ. F1 0,97


5.5.2 Metrik konumlandırma

Makro-F1 ölçütünde sonucumuz (0,612), veri kümesi makalesinin CNN temel sonuçlarının bandındadır (makro-F1 0,605–0,619); bu, üç ViT omurgasının füzyonunun güçlü CNN temellerine yakın bir makro başarımla sağladığını bağlamsal olarak gösterir. Yüksek doğruluk değerleri (EffiMix $\approx 98\%$, GastroViT $\approx 92\%$), farklı protokollerden ve dengesizlik altında iyimser olan toplu/ağırlıklı ölçütlerden kaynaklanır; nitekim Borgli’de de makro-F1 ($\approx 0,62$) ile mikro-F1/doğruluk ($\approx 0,91$) arasındaki açık, bu raporda gözlenen açıkla aynı dengesizlik olgusunu yansıtır. Bu nedenle güncel-en-iyi bir başarı iddiasında bulunulmamış; konum bağlamsal olarak sunulmuştur.

6 Tartışma

6.1 Hangi omurga daha iyi öznetelik öğrendi?

Dondurulmuş rejimde tek başına en güçlü omurga **Swin-T** olmuştur (makro-F1 0,576); bu, hiyerarşik kaydırmalı-pencere yapısının yerel doku ve çok ölçekli ipuçlarını (endoskopi görüntülerinde ayırt edici olan mukoza dokusu, damarlanma ve lezyon sınırları) iyi yakaladığını düşündürür. Saf ViT-B orta düzeyde, tek başına BEiT-B ise en zayıf omurgadır (0,522). Bu sıralama, öznetelik uzayının UMAP görselleştirmesinde de görülür (Şekil 6): ViT-B ve Swin-T izdüşümleri daha ayrık kümeler oluştururken, BEiT-B dağılımı daha iç içedir. Bununla birlikte BEiT-B, *tamamlayıcı* bir sinyal taşıdığı için füzyonda yine de değerlidir; tek başına zayıf olması, füzyondaki katkısını dışlamaz. Bu sıralama dondurulmuş eleme tablosuyla (Tablo 2) tutarlıdır: Swin’in yerel-çok ölçekli önyargısı endoskopinin doku ve sınır ipuçlarıyla uyumludur, ViT’in küresel öz-dikkati ve BEiT’in öz-denetimli temsili ise farklı yönlerden katkı sağlayarak füzyonun en güçlü tekil omurganın üzerine çıkmasını mümkün kılar.



Şekil 6: Dal başına izdüşürülmüş 512 boyutlu özneteliklerin UMAP’i (OOF test). ViT-B ve Swin-T daha ayrık kümeler verir; BEiT-B daha dağınıktır.

6.2 Füzyon işe yaradı mı?

Evet, ancak sınırlı ölçüde. Üçlü ağırlıklı füzyon, en iyi tekil omurgaya kıyasla hem ortalama hem havuzlanmış makro-F1’de önde olup (Tablo 5) eşli McNemar testinde *istatistiksel olarak anlamlı* biçimde daha doğrudur (Bölüm 5.4). Yani çok-omurga füzyonu, genel doğruluğa anlamlı bir katkı sağlar. Buna karşılık makro-F1 güven aralıkları kısmen örtüşür; çünkü füzyonun eklediği doğru tahminler ağırlıklı olarak zaten iyi sınıflandırılan yaygın sınıflardadır ve makro-F1, nadir sınıflarca sınırlanır. *Ağırlıklı* füzyon, *birleştirmeden* daha iyi sonuç vermiştir; bunun nedeni, birleştirmenin boyutu büyütüp daha fazla parametre gerektirmesi ve küçük veri rejiminde aşırı uyuma daha açık olmasıdır. Gelişmiş kapılı füzyon (GMU), özgün makaleye sadık öge-bazında kapı uygulanmasına rağmen ağırlıklı füzyonu geçememiştir (üçlü GMU 0,5525); bu da daha karmaşık füzyonun bu veri ölçeğinde ek kazanım getirmedeğini gösterir.

6.3 Hangi transfer yaklaşımı kazandı?

Son blokların ince ayarı, her eleme adayında dondurulmuş rejimi geçmiştir (Tablo 3). Bu beklenen bir sonuçtur: ImageNet ön-eğitilmiş öznetelikler genel olsa da, son dönüştürücü bloklarının endoskopi alanına uyarlanması ayırt ediciliği artırır. Süre açısından ince ayar, en iyi doğrulama makro-F1’ine erken ulaşır (üçlü yapılandırmada 6. epoch; Tablo 4), dolayısıyla eğitim birkaç epoch içinde yakınsar. Dondurulmuş rejim daha hızlıdır ve A100 gerektirmez; ince ayarın ek maliyeti ise verimlilik ayarlamalarıyla (TF32, bfloat16, veri yükleyici paralellliği) yaklaşık 5–6× azaltılarak bütçe içinde tutulmuştur. Dengesizliği ele almak için *ağırlıklı örnekleyici* doğru me-


kanızma olmuştur; son-işlem logit düzeltmesinin başarımı düşürmesi (Şekil 5), örnekleyicinin dengesizliği zaten ele aldığını ve ek bir önsel düzeltmesinin gereksiz/zararlı olduğunu doğrular.

6.4 Yorumlanabilirlik: model neye bakıyor?

Modelin karar gerekçelerini iki açıdan inceliyoruz: girdi üzerindeki dikkat ve aktivasyon haritaları ile füzyon öznetelik uzayının yapısı.

6.4.1 Dikkat ve Grad-CAM++

Dikkat yayılımı ve Grad-CAM++ haritaları, doğru sınıflandırılan örneklerde modelin *linik olarak anlamlı* bölgelere odaklandığını göstermektedir (Şekil 7). Örneğin retroflex konumundaki örneklerde model, endoskobun retrofleksiyon bölgesine; pilor görüntülerinde ise pilor halkasına yoğunlaşır. Hatalı örneklerde ise odak dağınıklaşır veya komşu yapıya kayar; bu, karışıklık matrisindeki ordinal/anatomik karışmalarla tutarlıdır.




(a) Dikkat yayılımı (doğru sınıf).

(b) Grad-CAM++ (nadir sınıf, hata içeren panel).

Şekil 7: Yorumlanabilirlik örnekleri. Doğru örneklerde odak klinik bölgededir; nadir/karışan sınıflarda odak dağınık. Swin dalının Grad-CAM++ haritası hiyerarşik pencere yerleşimi nedeniyle daha kaba (7×7) olduğundan ilgili panelde dipnotla işaretlenmiştir.

6.4.2 Öznetelik uzayı (UMAP)

Öznetelik uzayının füzyon sonrası UMAP'i (Şekil 8), yaygın sınıfların belirgin biçimde ayrıştığını, buna karşılık ülseratif kolit derecelerinin iç içe geçtiğini gösterir; bu, makro-F1 tavanının doğrudan görsel kanıtıdır.



Şekil 8: Füzyon öznitelikleri UMAP’i (OOF test, 23 sınıf). Ayırık kümeler = kolay sınıflar; iç içe bölge = karışan nadir sınıflar (ör. kolit dereceleri).

6.5 Hata analizi ve sınıf karışmaları

Karışıklık matrisi (Şekil 4) ve sınıf bazında metrikler, hataların rastgele dağılmadığını, büyük ölçüde *anlamsal veya anatomik olarak komşu* sınıflar arasında yoğunlaştığını gösterir. İlk hata türü *ordinal* şiddet karışmasıdır: ülseratif kolit dereceleri bitişik derecelere karışır; örneğin grade-1-2 ve grade-2-3 gibi ara dereceler büyük ölçüde komşu tam dereceler olarak tahmin edilir. Bu, derecelerin görsel olarak süreklilik göstermesi ve ara sınıfların çok düşük destekli olmasının birleşik sonucudur. İkinci hata türü *anatomik* benzerliktir: **hemorrhoids** örnekleri ağırlıklı olarak **retroflex-rectum**, **oesophagitis-a** ise **normal-z-line** olarak sınıflandırılır; bu sınıf çiftleri aynı anatomik bölgeyi paylaşır ve görünüm olarak yakındır. Buna karşılık belirgin ve yüksek destekli sınıflar (**normal-pylorus**, **retroflex-stomach**, **impacted-stool**) köşegende neredeyse hatasızdır. Klinik açıdan bu hatalar büyük ölçüde “yakın” hatalardır; tamamen ilgisiz sınıflara kayma seyrektr.

6.6 Dengesizliğin makro-F1 üzerindeki etkisi

Makro-F1 her sınıfa eşit ağırlık verdiğinden, çok düşük destekli nadir sınıflardaki düşük başarımla, yüksek genel doğruluğa rağmen makro-F1’i belirgin biçimde aşağı çeker; doğruluk (%88) ile makro-F1 ($\approx 0,61$) arasındaki açık bunun doğrudan ölçüsüdür. Bu davranış dengeli-hata bakış açısıyla tutarlıdır: dengesiz dağılımda çoğunluk sınıfları toplu ölçütleri iyimser kılar [17]. Dengesizliği ele almanın standart kaldıraçları arasında, iyi sınıflandırılan örneklerin kaybını azaltıp zor ve nadir örneklerle odaklanan odak kaybı (focal loss) [13] ve nadir sınıfları yeniden örnekleyen sınıf-dengeli örnekleme bulunur. Bu çalışmada eğitimde ters-frekanslı ağırlıklı örnekleyici kullanılmış, ayrıca son-işlem logit düzeltmesi denenmiştir. Logit düzeltmesinin başarımı düşürmesi (Bölüm 5.4), örnekleyicinin dengesizliği zaten ele aldığını ve modelin örtük önselinin yaklaşık tekdüze olduğunu gösterir. Nadir sınıflardaki temel sınır ise bir model değil veri kıtlığı sorunudur: bazı sınıfların onlu sayılarda örneği vardır ve hiçbir kayıp ya da örnekleme düzenlemesi eksik veriyi telafi edemez.

6.7 Aynı protokol altında CNN füzyonu ile karşılaştırma

Aynı veri kümesi, aynı resmi 5-katlı protokol, sızıntıya karşı denetlenmiş OOF değerlendirme ve aynı füzyon çerçevesi (birleştirme/ağırlıklı/GMU + MLP) altında eğitilen CNN-omurgalı bir füzyon modeli, doğrudan ve kontrollü bir karşılaştırma olanağı sağlar; yalnız omurga ailesi değişir (CNN: ResNet-50 + MobileNetV2 + EfficientNet-B0). Tablo 9 iki ailenin nihai modellerini karşılaştırır.

Tablo 9: Kontrollü karşılaştırma: aynı veri kümesi, protokol ve füzyon çerçevesi altında CNN-omurgalı ve ViT-omurgalı füzyon (havuzlanmış OOF, $n = 10.662$; makro-F1 ana ölçüt). Reçete: ViT temel (TTA kazanç vermedi), CNN test zamanı veri artırmalı.

Aile (omurgalar)	Reçete	Makro-F1	Doğruluk	MCC
ViT (ViT-B + Swin-T + BEiT-B)	temel	0,6119	0,8779	0,868
CNN (ResNet-50 + MobileNetV2 + EfficientNet-B0)	+TTA	0,6075	0,8765	0,866

İki aile istatistiksel olarak *denktir*: makro-F1 güven aralıkları örtüşür, doğruluk ve MCC değerleri neredeyse aynıdır. Aynı temel (TTA'sız) reçete altında bile CNN füzyonunun makro-F1'i (0,600), ViT füzyonunun güven aralığı içinde kalır. Dolayısıyla bir aile diğerine belirgin bir üstünlük sağlamaz; her ikisi de aynı nadir-sınıf tavanına ulaşır. Bu bulgu, başarıyı sınırlayan etkenin omurga ailesi değil, düşük destekli sınıflardaki veri kıtlığı olduğunu güçlü biçimde destekler.

Bu ortak tavan, yöntemden bağımsız sonuçlarla da tutarlıdır: odak kaybı, test zamanı veri artırma ve seed topluluğu gibi toplamsal teknikler her iki ailede de en iyi çapraz-entropi yapılandırmasını güven aralığı düzeyinde geçememiştir. Yöntemsel olarak bu çalışma, CNN-omurgalı füzyonun açık bıraktığı yönleri ele alır: dönüştürücü omurgalar ile dikkat yayılımı ve Grad-CAM++ temelli yorumlanabilirlik burada uygulanırken, iki ailede de kazanç sağlamayan teknikler bir kenara bırakılmıştır.

6.8 Güçlü ve zayıf yönler

Çalışmanın katkılarını ve sınırlarını, her birini mevcut bulgulara bağlayarak iki başlık altında topluyoruz.

6.8.1 Güçlü yönler

- **Anlamli füzyon kazancı.** Üç tamamlayıcı ViT omurgasının ağırlıklı füzyonu, en iyi tekli omurgadan ve en iyi ikiliden eşli McNemar testinde istatistiksel olarak anlamlı biçimde daha doğrudur (Bölüm 5.4); ortalama ve havuzlanmış makro-F1'de de öndedir (Tablo 5).
- **Temel-bandı makro başarımlı.** Makro-F1 (0,612) ve MCC (0,868), veri kümesi makalesinin CNN temellerinin bandındadır (Tablo 8); bu, çok-ViT füzyonunun güçlü CNN temellerine yakın bir makro başarımlı sağladığını bağlamsal olarak gösterir.
- **Titiz değerlendirme.** Sızıntıya karşı denetlenmiş resmi 5-katlı protokol ve önyükleme %95 güven aralıkları, sonuçların güvenilirliğini destekler (Tablo 5).
- **Yorumlanabilirlik.** Dikkat yayılımı ve Grad-CAM++ haritaları kararların klinik bölgelerle ilişkili olduğunu, UMAP ise sınıf ayrışmasını gösterir (Şekil 7, 8).
- **Dürüst ve eksiksiz analiz.** Kazanç sağlamayan teknikler (GMU, TTA, seed topluluğu, logit düzeltmesi) gizlenmeden raporlanmıştır (Tablo 7, Şekil 5).
- **Verimlilik.** İnce ayar maliyeti, verimlilik ayarıyla yaklaşık 5–6× azaltılarak bütçe içinde tutulmuştur (Tablo 4).

6.8.2 Sınırlamalar

- **Nadir-sınıf tavanı.** Çok düşük destekli sınıflarda (ör. `hemorrhoids: 6`, `ulcerative-colitis-grade-1-2: 11`) F1 sıfıra iner (Tablo 6); bu bir model değil *veri kıtlığı* sınırıdır ve makro-F1'i belirleyen ana etkidir.
- **Sınırlı makro-F1 kazancı.** Füzyonun katkısı doğruluk düzeyinde anlamlı olsa da, makro-F1 güven aralıkları kısmen örtüşür; kazanç ağırlıklı olarak zaten iyi sınıflandırılan yaygın sınıflardan gelir.
- **Klinik olarak “yakın” hatalar.** Hatalar büyük ölçüde ordinal (kolit dereceleri) veya anatomik (`hemorrhoids`→`retroflex-rectum`) komşu sınıflar arasındadır.
- **Mimari sınırları.** Tek başına BEiT en zayıf omurgadır ve daha karmaşık kapılı füzyon (GMU) ağırlıklı füzyona ek kazanç getirmemiştir.
- **Yaklaşık üreme.** Ayarlı bfloat16/TF32 yolu, yalnızca çok düşük marjlı örneklerde nadir argmax değişimlerine yol açan yaklaşık bir üreme sağlar.
- **Tek veri kümesi.** Değerlendirme tek bir veri kümesi ve tek bölme protokolüyle sınırlıdır; klinik ya da dış doğrulama yapılmamıştır.

7 Sonuç

Bu çalışmada, HiperKvasir 23-sınıf GI endoskopi sınıflandırması için çoklu ViT tabanlı bir özellik füzyonu yaklaşımı sunulmuştur. Üç tamamlayıcı omurganın (ViT-B/16, Swin-T, BEiT-B/16) ağırlıklı füzyonunun ince ayarlı sürümü, resmi 5-katlı protokolde en iyi yapılandırma olmuş; havuzlanmış makro-F1 0,6119 (%95 GA [0,5930, 0,6295]), doğruluk $\approx 0,88$ elde edilmiştir. Bu yapılandırma, eşli McNemar testinde hem en iyi tekli omurgadan hem de en iyi ikili füzyondan istatistiksel olarak anlamlı biçimde daha doğrudur.

Çalışmanın temel çıkarımları şunlardır: (i) çok-omurga füzyonu genel doğruluğa anlamlı bir katkı sağlar, ancak makro-F1 kazancı nadir sınıflarca sınırlanır; (ii) ağırlıklı füzyon, birleştirme ve gelişmiş GMU füzyonundan daha iyi/eşdeğer sonuç vermiştir; (iii) son blokların ince ayarı dondurulmuş öznitelik çıkarımını geçmiştir; (iv) dengesizlik için ağırlıklı örnekleyici yeterli olup son-işlem logit düzeltmesi başarıyı düşürmüştür. TTA ve seed topluluğu gibi toplamsal teknikler güven aralığı düzeyinde ayırt edilebilir bir iyileşme getirmemiştir; bu, mimarinin bu protokolde tavanına ulaştığını gösterir.

Sınırlamalar ve gelecek çalışmalar. Temel sınırlama, çok düşük destekli nadir sınıflardan kaynaklanan bir veri kıtlığıdır. Gelecekte; (a) ordinal yapıyı (ör. kolit dereceleri) açıkça modelleyen sıralı sınıflandırma kayıpları, (b) nadir sınıflar için hedefli veri toplama, üretici artırma veya odak kaybı gibi dengesizlik-duyarlı kayıplar [13], ve (c) klinik açıdan “yakın” hataları ayrıştıracak ince taneli ayırım öğrenme yaklaşımları umut verici yönlerdir. Bildirilen sayıların tümü kaydedilen değerlendirme çıktılarına dayanır; literatür karşılaştırmaları protokol farkları nedeniyle bağlamsaldır ve güncel-en-iyi bir başarı iddiasında bulunulmamıştır.

Proje deposu. Kaynak kod, eğitim çıktıları ve tanıtım videosu bağlantısı proje deposunda yer alır: <https://github.com/YasinEkici/hyperkvasir-multi-backbone-fusion>.

A Sınıf bazında ayrıntılı metrikler

Tablo 10, nihai modelin havuzlanmış OOF test kümesindeki ($n = 10.662$) 23 sınıfın tamamı için kesinlik, duyarlılık, F1 ve destek değerlerini verir (F1'e göre artan sırada). Düşük destekli sınıflarla düşük F1 arasındaki güçlü ilişki açıkça görülür.


Tablo 10: Nihai model: tüm sınıflar için sınıf bazında metrikler (havuzlanmış OOF).

Sınıf	Kesinlik	Duyarlılık	F1	Destek
hemorrhoids	0,000	0,000	0,000	6
ulcerative-colitis-grade-1-2	0,000	0,000	0,000	11
ulcerative-colitis-grade-2-3	0,054	0,071	0,062	28
ileum	0,500	0,111	0,182	9
short-segment-barretts	0,200	0,189	0,194	53
barretts	0,214	0,220	0,217	41
ulcerative-colitis-grade-0-1	0,222	0,286	0,250	35
ulcerative-colitis-grade-1	0,470	0,388	0,425	201
oesophagitis-a	0,442	0,519	0,477	403
ulcerative-colitis-grade-3	0,608	0,677	0,641	133
ulcerative-colitis-grade-2	0,664	0,700	0,681	443
oesophagitis-b-d	0,660	0,746	0,700	260
normal-z-line	0,837	0,754	0,794	932
impacted-stool	0,692	0,992	0,815	131
dyed-resection-margins	0,932	0,894	0,912	989
dyed-lifted-polyps	0,896	0,937	0,916	1002
retroflex-rectum	0,914	0,974	0,943	391
polyp	0,995	0,941	0,967	1028
bbps-2-3	0,996	0,948	0,971	1148
bbps-0-1	0,980	0,974	0,977	646
normal-cecum	0,977	0,976	0,977	1009
normal-pylorus	0,978	0,987	0,983	999
retroflex-stomach	0,991	0,988	0,990	764

B Ek yorumlanabilirlik panelleri


Şekil 9, ana metni tamamlayan ek örnekler sunar: yaygın ve iyi sınıflandırılan bir sınıfta dikkat yayılımı ile çok düşük destekli, hatalı sınıflandırılan bir sınıfta Grad-CAM++. Yaygın sınıfta odak klinik bölgede toplanırken, nadir sınıfta dağınıklaşır.

Attention rollout — class 'normal-pylorus' (F1=0.99, n=199)



(a) Dikkat yayılımı: **normal-pylorus** (yaygın, doğru).

Grad-CAM++ — class 'hemorrhoids' (F1=0.00, n=1) *Swin = coarse windowed map



(b) Grad-CAM++: **hemorrhoids** (çok düşük destek, hata).

Şekil 9: Ek yorumlanabilirlik panelleri. Üst: yaygın bir sınıfta dikkat yayılımı; alt: nadir bir sınıfta Grad-CAM++ (Swin dalı hiyerarşik pencere yerleşimi nedeniyle daha kaba bir harita verir).

Kaynaklar

- [1] Samira Abnar and Willem Zuidema. Quantifying attention flow in transformers. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.

- [2] Ibrahim Abdulrab Ahmed, Ebrahim Mohammed Senan, and Hamzeh Salameh Ahmad Shatnawi. Hybrid models for endoscopy image analysis for early detection of gastrointestinal diseases based on fused features. *GI endoscopy, feature fusion (contextual)*, 2023.
- [3] Anonymous et al. GastroViT: A vision transformer ensemble for gastrointestinal disease classification. *arXiv preprint, HyperKvasir comparator (contextual)*, 2025.
- [4] John Arevalo, Thamar Solorio, Manuel Montes-y Gómez, and Fabio A. González. Gated multimodal units for information fusion. In *International Conference on Learning Representations (ICLR) Workshop*, 2017.
- [5] Hangbo Bao, Li Dong, Songhao Piao, and Furu Wei. BEiT: BERT pre-training of image transformers. In *International Conference on Learning Representations (ICLR)*, 2022.
- [6] Hanna Borgli, Vajira Thambawita, Pia H. Smedsrud, et al. HyperKvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy. *Scientific Data*, 7(283), 2020.
- [7] Aditya Chattopadhyay, Anirban Sarkar, Prantik Howlader, and Vineeth N. Balasubramanian. Grad-CAM++: Improved visual explanations for deep convolutional networks. *IEEE Winter Conference on Applications of Computer Vision (WACV)*, 2018.
- [8] Thomas G. Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923, 1998.
- [9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- [10] Guo et al. Improving image classification of gastrointestinal endoscopy using curriculum self-supervised learning. *GI endoscopy, self-supervised learning (contextual)*, 2024.
- [11] He et al. HEMF: An adaptive hierarchical enhanced multi-attention feature fusion framework for cross-scale medical image classification. *Multi-attention feature fusion, medical imaging (contextual)*, 2025.
- [12] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018.
- [13] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [14] Ze Liu, Yutong Lin, Yue Cao, et al. Swin transformer: Hierarchical vision transformer using shifted windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [15] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [16] Leland McInnes, John Healy, and James Melville. UMAP: Uniform manifold approximation and projection. *Journal of Open Source Software*, 2018.
- [17] Aditya Krishna Menon, Sadeep Jayasumana, Ankit Singh Rawat, et al. Long-tail learning via logit adjustment. In *International Conference on Learning Representations (ICLR)*, 2020.

- [18] Karthik Ramamurthy et al. EffiMix: An efficient mixing approach for gastrointestinal image classification. *HyperKvasir comparator (contextual; different protocol)*, 2022.
- [19] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [20] Aliza Subedi, Smriti Regmi, Nisha Regmi, Bhumi Bhusal, Ulas Bagci, and Debesh Jha. Classification of endoscopy and video capsule images using cnn-transformer model. 2024.
- [21] Daniel Varam et al. Wireless capsule endoscopy image classification with lightweight (edge) vision transformers. *Applied Sciences, Kvasir-Capsule (contextual; different dataset)*, 2024.
- [22] H. Wang et al. A hierarchical shifted-window vision transformer for gastrointestinal endoscopic image classification. *HyperKvasir comparator (contextual; different protocol)*, 2023.